

第十四周作业

第十四周作业

提高作业

2.1 Learning-based Decision 调研

查阅文献，调研机器人决策中的 Learning-based Decision 方法。请介绍一种 VLA 方法，再介绍一种 World Model 方法。

完成内容：

- 说明所选 VLA 方法的基本思路、输入信息和输出决策；
- 说明所选 World Model 方法的基本思路、输入信息和输出决策；
- 比较两类方法的数据来源、适用任务、优势和风险。

提交内容：

- 一种 VLA 方法介绍；
- 一种 World Model 方法介绍；
- VLA 与 World Model 的对比表。

一、VLA 方法介绍：RT-2（Robotics Transformer 2）

1.1 论文信息

项目	内容
论文标题	RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control
团队	Google DeepMind
发表时间	2023.07（arXiv: 2307.15818）
核心贡献	首次证明大规模视觉 - 语言模型（VLM）可以直接作为机器人控制策略，将互联网知识迁移至机器人动作空间


1.2 基本思路

RT-2 的核心思想是：将机器人动作（**Action**）表示为文本 **token**，从而让预训练好的大型视觉 - 语言模型（**VLM**）可以直接输出机器人控制指令。传统方法需要分别训练视觉理解、语言理解和动作生成三个独立模块；RT-2 将它们统一在一个端到端的 Transformer 模型中：

传统方法：视觉模块 → 语言理解 → 规划器 → 控制器
RT-2：[图像 + 语言指令] → 统一 VLM → [动作 token]

关键创新：将连续的机器人动作空间（7-DoF 末端执行器位姿 + 夹爪开合）离散化为 **256 个 bin**，映射到文本 vocabulary 中的 token。这样，VLM 的 next-token prediction 训练目标就自然包含了 " 预测下一步动作 "。

1.3 网络架构



1.4 输入信息

输入	格式	说明
RGB 图像	320×320 像素	机器人头部摄像头的当前帧
自然语言指令	文本字符串	任务描述，例如 "pick up the red block"
(可选) 历史帧	前 6 帧图像	提供短期运动上下文

没有深度图、点云、力/力矩传感器、关节编码器等信息——全部依赖视觉 + 语言。

1.5 输出决策

输出	维度	含义
$\Delta x, \Delta y, \Delta z$	3	末端执行器平移增量
$\Delta r_x, \Delta r_y, \Delta r_z$	3	末端执行器旋转增量
gripper	1	夹爪开合（0=关 / 1=开）

输出	维度	含义
terminate	1	是否结束当前任务（episode termination）

每个值被离散化为 256 个 bin（以文本 token 表示），模型通过自回归方式依次输出 8 个 token。

1.6 训练数据与流程

第一阶段（预训练）：

└ 互联网规模的 图像-文本 对（数十亿对）→ 学习视觉语义理解

第二阶段（联合微调 co-fine-tuning）：

└ 原始 VQA / 字幕 任务数据（保持语言能力不退化）

└ 机器人 demonstration 数据（约 13 万条轨迹）
→ 学习 "图像+语言 → 动作token" 的映射

1.7 突出能力：涌现的语义泛化

RT-2 展现了一般 robot learning 方法不具备的涌现能力（Emergent Capabilities）：

能力	示例
语义推理	" 把垃圾移到垃圾桶 "——理解抓拿可乐罐→放到垃圾桶
数学/符号推理	" 挑出数量最少的物品 "
多语言	接受日语/法语指令
未见物体	对训练中从未出现过的物体执行操作

这些能力来源于 VLM 预训练时吸收的互联网知识，RT-2 成功将其迁移到动作空间。

二、World Model 方法介绍：DayDreamer

2.1 论文信息

项目	内容
论文标题	DayDreamer: World Models for Physical Robot Learning
团队	UC Berkeley（Danijar Hafner 等）
发表时间	2022（CoRL 2022）
核心贡献	首次在真实物理机器人上证明 World Model（世界模型）可以实现高效的在线学习，仅需 1 小时真实交互即可学会行走

2.2 基本思路

DayDreamer 的核心理念是：先在真实环境中少量交互收集数据，用这些数据训练一个 " 世界模型 " 来模拟环境动态，然后在想象中大量 " 做梦 " 训练策略，最后再回到真实环境验证和补充数据。

传统 Model-Free RL：

机器人 ↔ 真实环境（需数百万步交互）→ 太慢、太危险

DayDreamer (Model-Based RL)：

Step 1: 少量真实交互 → 收集 D_real


Step 2: 训练 World Model（学习环境动态）

Step 3: 在 World Model 中"做梦"数千条想象轨迹 → 训练策略

Step 4: 回到真实环境执行策略 → 补充新数据 → 回到 Step 2

这种方法极大地减少了真实交互量，使得在真机上直接学习变得可行。

2.3 网络架构（基于 DreamerV2）



1 RSSM（Recurrent State Space Model）— 世界模型核心

确定性路径: $h_t = f_\theta(h_{t-1}, z_{t-1}, a_{t-1})$

随机性路径: $z_t \sim q_\phi(z_t | h_t, o_t)$

先验预测: $\hat{z}_t \sim p_\theta(z_t | h_t)$

← GRU 记忆长期状态

← 后验 (有观测时)

← 先验 ("做梦"时使用)

确定性 + 随机性的双路径设计让世界模型既能保持长程记忆，又能捕捉环境中的随机性。

1 2.4 输入信息

输入	格式	说明
RGB 图像	64×64 像素	机器人头部/侧方摄像头
本体感觉	向量	关节角度、角速度、IMU 读数等
上一步动作	向量	上一个时间步执行的动作
奖励信号	标量	任务相关的奖励（如前进速度、站立高度）


与 RT-2 不同，DayDreamer 不需要自然语言指令，但需要设计奖励函数。

1 2.5 输出决策

输出	格式	说明
连续动作	N 维向量	各关节的目标力矩或位置指令
（内部）预测的未来状态	隐状态序列	用于策略优化，不直接输出
（内部）预测的奖励	标量序列	用于估计长期回报

以 A1 四足机器人为例，输出 12 维关节角度增量（4 条腿 × 3 个关节）。

1 2.6 训练流程



1 2.7 实验成果

机器人平台	任务	真实交互时间	成果
A1 四足机器人	户外行走	3 / 141 小时	学会稳定前进

机器人平台	任务	真实交互时间	成果
UR5 机械臂	抓取翻转物体	2.5 小时	成功率 > 90%
XArm	拾取放置	1.5 小时	成功率 > 80%

对比：传统 model-free RL（如 SAC）需要数十至数百小时的真实交互。

三、VLA 与 World Model 全面对比

3.1 核心维度对比表

对比维度	RT-2（VLA）	DayDreamer（World Model）
基本范式	视觉 - 语言模型直接映射到动作	先学环境模型，再在想象中训练策略
模型基础	预训练 VLM（PaLI-X 55B）	RSSM 世界模型 + Actor-Critic
参数规模	12B ~ 55B	~100M
训练方式	预训练 + 联合微调	在线交互学习（边执行边学）
是否需要人类示教数据	✅ 需要（约 13 万条 demo 轨迹）	❌ 不需要（仅需奖励函数）
是否需要奖励函数	❌ 不需要	✅ 需要手工设计
是否需要语言指令	✅ 需要	❌ 不需要

3.2 数据来源对比

维度	RT-2（VLA）	DayDreamer（World Model）
预训练数据	互联网图像 - 文本对（数十亿级）	无预训练（从零开始）
任务数据	人类遥操作 demonstration（13 万轨迹）	机器人自主探索（随机策略 + 学习策略）
数据获取成本	🔴 极高 — 需要大规模人工遥操作	🟢 较低 — 机器人自己收集
数据多样性	🟢 高（互联网知识 + 多种物体/场景）	🔴 受限于当前环境
数据标注	语言指令 + 动作序列	奖励信号（可自动计算）

3.3 适用任务对比

任务类型	RT-2（VLA）	DayDreamer（World Model）
语言指令的操作任务	✅ 强项	❌ 不支持语言
未见物体/场景泛化	✅ 强（互联网知识迁移）	❌ 弱（只知道交互过的）
连续运动控制（行走/飞行）	❌ 弱（离散化损失精度）	✅ 强项
高频闭环控制	❌ 受限（推理延迟高）	✅ 支持（模型小、推理快）
新环境快速适应	❌ 需重新收集 demo	✅ 强（1h 在线学习）
长程规划	❌ 逐帧反应式	✅ 可在想象中展开未来

3.4 优势与风险对比

RT-2（VLA）优势

优势	说明
🌐 互联网知识迁移	预训练吸收的海量常识可直接用于机器人任务
🗣️ 自然语言交互	用户可以用日常语言下达开放式指令
🎯 强泛化能力	对训练中未见的物体/概念也能处理（涌现能力）
🔧 端到端简洁	不需要手工设计感知→规划→控制 pipeline

RT-2（VLA）风险

风险	说明
🕒 推理延迟高	55B 模型推理 ~100ms/帧，不适合高频控制（>30Hz）
💰 部署成本大	需要 TPU/大量 GPU，边缘部署困难
📄 动作精度有限	256-bin 离散化限制了精细操作
🔒 黑盒不可解释	大模型决策过程难以理解和调试
🤖 硬件绑定	训练数据来自特定机器人，跨硬件迁移需重新收集数据
⚠️ 安全性未验证	可能产生不安全的动作（幻觉问题）

DayDreamer（World Model）优势

第十四周作业-2	
优势	说明
 样本效率极高	1 小时真实交互 = 传统方法数百小时
 想象中安全探索	危险动作在世界模型中试错，不损坏真机
 连续精细控制	输出连续动作向量，适合力矩/关节控制
 推理速度快	~100M 参数，可在边缘设备实时运行
 持续在线学习	无需离线收集大数据集，边部署边改进

DayDreamer（World Model）风险

风险	说明
 世界模型偏差	模型预测不准确时，策略在真实环境中会失效（model bias）
 长程预测衰减	想象展开步数越多，预测误差累积越大
 奖励工程困难	需要人工设计奖励函数，复杂任务的奖励很难定义
 不理解语义	无法处理语言指令或抽象概念
 泛化能力有限	换环境/换机器人需要重新训练世界模型

3.5 综合评价雷达图（定性）



四、总结与展望

结论	说明
选 VLA 当...	需要语言交互、物体种类多、任务开放式、精度要求不极高
选 World Model 当...	需要高频精细控制、不想收集大量人工 demo、要求在线快速适应
未来趋势	两类方法正在融合——用 VLM 提供语义理解和高层目标，用 World Model 做底层运动规划和安全验证

融合示例：最新工作如 **UniPi**（2023）、**SuSIE**（2023）、**3D-VLA**（2024）正在探索 "VLM 提供语义子目标 → World Model 规划连续动作序列 " 的混合架构，有望兼得两者优势。

参考文献

- Brohan, A., et al. "RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control." *arXiv:2307.15818*, 2023.
- Hafner, D., et al. "DayDreamer: World Models for Physical Robot Learning." *CoRL*, 2022.
- Brohan, A., et al. "RT-1: Robotics Transformer for Real-World Control at Scale." *RSS*, 2023.
- Hafner, D., et al. "Mastering Diverse Domains through World Models (DreamerV3)." *arXiv:2301.04104*, 2023.
- Du, Y., et al. "UniPi: Learning Universal Policies via Text-Guided Video Generation." *NeurIPS*, 2023.
- Zhen, H., et al. "3D-VLA: A 3D Vision-Language-Action Generative World Model." *ICML*, 2024.

2.2 学习式机器人决策路线设计

选择一个具体机器人任务，设计一条基于 VLA 或 World Model 的决策技术路线，可以参考已有研究。例如机器人根据视觉和语言完成射门、取物、抓取、巡检或仓储搬运等场景。

完成内容：

- 说明任务场景、机器人平台、传感器输入和动作空间；
- 画出从感知输入到模型决策，再到机器人动作执行的技术路线图；
- 说明数据采集、模型输入输出、安全约束和执行流程；
- 分析这条路线相比规则式 FSM / 行为树的优势、风险和落地难点。

提交内容：

- 任务场景说明；

- 学习式决策技术路线图；
- 数据、模型、安全约束和落地分析。

以下基于 VLA 的仓储拣货机器人学习式决策技术路线

一、任务场景说明

1.1 场景描述

场景：电商仓库自动拣货（Warehouse Order Picking）

仓库货架上存放着数千种形态各异的商品（盒装、袋装、瓶装、异形件等）。移动操作机器人（Mobile Manipulator）接收订单指令，自主导航至目标货架，识别并抓取指定商品，放入随行料箱，完成一次拣货。

典型工作流（一次拣货）：

- ① 接收语言化订单 → ② 导航至目标货架 → ③ 视觉定位目标商品
→ ④ 规划手臂轨迹 → ⑤ 抓取 → ⑥ 放入料箱 → ⑦ 前往下一货位或返回

1.2 为什么选择 VLA?

挑战	为什么 VLA 比 FSM/BT 更适合
商品种类成千上万，且频繁更换	VLA 的 VLM 预训练具备开放词汇物体识别能力，无需为每种商品单独训练检测器
指令形式多样	VLA 天然理解 " 拿第二层左边的红色盒子 "、"pick the shampoo bottle" 等自然语言
抓取姿态因物体而异	端到端学习映射，自动学习不同物体的最佳抓取策略
货架场景复杂且遮挡多	VLM 的语义理解能力可以处理部分遮挡和密集摆放

1.3 机器人平台

项目	规格
移动底盘	全向轮底盘（如 Clearpath Ridgeback），支持自主导航
机械臂	7-DoF 协作臂（如 Franka Emika Panda / Kinova Gen3）
末端执行器	两指自适应夹爪（Robotiq 2F-85）+ 吸盘（双工具快换）
算力平台	机载 NVIDIA Jetson AGX Orin（边缘推理）+ 云端 GPU 集群（VLA 推理）

1.4 传感器配置

传感器	型号示例	安装位置	用途
RGB-D 相机（主）	Intel RealSense D435i	手腕（Eye-in-Hand）	近距离精确定位商品
RGB-D 相机（辅）	RealSense D455	底盘上方（Eye-to-Hand）	货架全局视野
2D LiDAR	SICK TiM571	底盘前后	导航 + 避障
力/力矩传感器	ATI Mini45	腕部	抓取力控 + 碰撞检测
关节编码器	内置	各关节	关节角度/速度反馈
夹爪状态传感器	内置	末端	夹爪开合度 + 是否夹住物体

1.5 动作空间定义


决策层级	动作空间	维度	控制频率
高层导航	目标航点 (x, y, θ)	3D 连续	1 Hz
VLA 操作	末端执行器增量 Δpose + 夹爪	7D 连续 → 256-bin 离散	5 Hz
底层控制	关节力矩/位置指令	7D 连续	500 Hz

VLA 动作空间（每步输出）：


- a_t = [Δx, Δy, Δz, Δroll, Δpitch, Δyaw, gripper_state]
└─ 末端位置增量 (米) ─┘ └─ 旋转增量 (弧度) ─┘ └─ 0/1

二、技术路线图

2.1 整体架构图



2.2 时序执行流程图




三、数据采集方案

3.1 数据来源分层

层级	数据类型	规模	获取方式
预训练	互联网图像 - 文本对	~10B 对	使用已有 VLM（如 PaLI-X），不需自行收集
域适配	仓库场景图像 + 商品标注	~50 万张	部署摄像头自动拍摄 + 半自动标注
操作示教	人类遥操作抓取轨迹	~5 万条	遥操作系统收集
仿真增强	仿真环境合成轨迹	~50 万条	IsaacSim / MuJoCo 仿真

3.2 示教数据采集流程




```
{
  "trajectory_id": "traj_00142",
  "language_instruction": "Pick the yellow cereal box from the second shelf on the left",
  "language_variants": [
    "grab the cereal from shelf 2",
    "拿第二层左边的黄色麦片盒",
    "take the yellow box, second row"
  ],
  "object_category": "cereal_box",
  "shelf_location": "B-2-L",
  "grasp_type": "top_pinch",
  "success": true,
  "steps": 47,
  "duration_s": 9.4
}
```

四、模型输入输出详细设计

4.1 模型输入


输入项	张量形状	说明
当前 RGB 图像	[1, 3, 320, 320]	手腕相机 resize + center crop
历史 5 帧 RGB	[5, 3, 320, 320]	提供运动上下文
语言指令 token	[1, max_len=64]	tokenizer 编码
本体感觉	[1, 14]	7 关节角 + 7 关节角速度
夹爪状态	[1, 2]	开合度 + 是否接触

4.2 模型输出

输出项	张量形状	值域	说明
$\Delta x, \Delta y, \Delta z$	[3]	$[-0.05, +0.05]$ m	末端平移增量
$\Delta roll, \Delta pitch, \Delta yaw$	[3]	$[-15^\circ, +15^\circ]$	末端旋转增量
gripper	[1]	{0, 1}	0=关, 1=开
terminate	[1]	{0, 1}	是否结束当前操作

每个连续值离散化为 **256 个 bin**（均匀分桶），模型以 8 个 token 的自回归方式输出。

4.3 模型结构细节




4.4 训练配置

配置项	值
预训练 VLM	PaLI-X 3B / Florence-2（冻结视觉编码器）
微调策略	LoRA（rank=16）+ 动作头全量训练
训练数据	5 万真实 demo + 50 万仿真 demo（混合比 1:10）
联合训练	50% 机器人数据 + 50% 原始 VQA 数据（防止遗忘）
优化器	AdamW, lr=2e-5, cosine 退火
Batch size	256
训练时长	~48h on 8xA100
推理延迟	~150ms / 步（Jetson AGX Orin，INT8 量化后）

五、安全约束体系


5.1 四层安全防护架构





5.2 关键安全规则

规则	触发条件	动作
碰撞检测停止	力传感器 $> 30N$	立即冻结所有关节
工作空间越界	末端位置超出安全包络	裁剪动作到边界，继续执行
异常动作检测	连续 3 步动作方差 $>$ 阈值	暂停 VLA 推理，保持当前姿态
超时保护	单次抓取 $> 30s$ 无进展	回撤至安全位姿，报告失败
通信中断	VLA 模型响应 $> 500ms$	切换至安全姿态保持 (fallback)

六、完整执行流程







七、与规则式 FSM / 行为树的对比分析

7.1 全维度对比表

对比维度	FSM / 行为树	VLA（本方案）
架构	手工设计状态/节点，if-else 规则	端到端神经网络，数据驱动
感知方式	需要独立视觉 pipeline（检测→分割→位姿估计）	端到端（图像直接到动作）
语言理解	❌ 不支持（或需额外 NLP 模块）	✅ 原生支持自然语言指令
新物体适应	🔴 需为每种新物体配置检测器/抓取策略	🟢 预训练的开放词汇能力，可直接处理未见物体
开发周期	数周（每新增物体需调参）	一次训练，多物体通用
决策透明度	🟢 完全可解释，状态转移清晰	🔴 黑盒，难以解释具体决策原因
确定性	🟢 相同输入一定产生相同输出	🔴 存在随机性和不可预测行为
实时性	🟢 < 1ms（纯逻辑判断）	🟡 ~150ms（神经网络推理）
安全保障	🟢 可形式化验证	🔴 需额外安全约束层（不可证明安全）
数据需求	🟢 无需训练数据	🔴 需要数万条示教轨迹
维护成本	🟡 规则膨胀后难维护	🟡 模型更新需重新训练
异常处理	🟢 可手动覆盖所有异常路径	🔴 未见异常场景可能行为不可控

7.2 VLA 方案的核心优势

优势	详细说明
① 泛化能力强	互联网预训练赋予 VLM 对数千种物体的语义理解，无需逐一建模。FSM/BT 面对 SKU 更换时需要人工更新检测器和抓取规则
② 端到端简洁	省去了传统 pipeline 中的物体检测→6DoF 位姿估计→抓取规划→运动规划 多个独立模块，减少级联误差
③ 自然语言灵活	用户/调度系统可以用自然语言描述任意抓取意图，包括相对位置、颜色、材质等属性，FSM/BT 无法理解
④ 隐式技能迁移	训练数据中的多种抓取技巧（侧抓、顶抓、捏取）会隐式编码在模型中，根据物体形态自动选择


7.3 VLA 方案的风险与挑战

风险	严重程度	应对策略
推理延迟导致控制滞后	🟡 中	INT8 量化 + TensorRT 加速，将延迟压至 100ms 以内；高频力控由底层 PID 兜底
幻觉/错误动作	🔴 高	四层安全约束体系（见第五节）；力传感器碰撞检测作为最终防线
训练数据偏差	🟡 中	仿真 + 真实混合训练；持续在线收集失败案例并 fine-tune
模型不可解释	🟡 中	部署 Grad-CAM 可视化注意力区域；保留操作日志供回溯
边缘部署算力不足	🟡 中	模型蒸馏至 1B 以下；或采用云边协同方案
通信延迟/中断	🟡 中	云端推理时预留 fallback 策略（本地简单 FSM 兜底）

7.4 落地难点分析

难点	现状	建议方案
① 示教数据采集成本高	5 万条真实轨迹 ≈ 数千人·时	仿真增强（仿真: 真实=10:1）+ 数据共享（跨仓库复用）
② 推理算力限制	Jetson Orin ~200 TOPS	模型蒸馏（55B → 3B → 1B）+ 异步推理（推理与执行流水线化）
③ 安全认证难	VLA 无法形式化验证	混合架构：VLA 做高层决策 + 传统安全层兜底；安全关键逻辑不经过 VLA
④ Sim-to-Real Gap	仿真训练的策略迁移到真机时性能下降	域随机化（纹理/光照/物理参数）+ 少量真机 fine-tune
⑤ 长尾场景覆盖	异形件、透明物体、堆叠遮挡	持续学习：部署后收集失败案例，定期重新训练；极端案例由人工远程接管

实际部署中，纯 VLA 方案风险过高。推荐采用 "VLA 脑 + FSM 手 " 混合架构：



这样既能享受 VLA 的语义理解和泛化能力，又能通过 FSM/BT 保证安全性和可靠性。

参考文献

- Brohan, A., et al. "RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control." *arXiv:2307.15818*, 2023.
- Brohan, A., et al. "RT-1: Robotics Transformer for Real-World Control at Scale." *RSS*, 2023.
- Kim, M. J., et al. "OpenVLA: An Open-Source Vision-Language-Action Model." *arXiv:2406.09246*, 2024.
- Zhen, H., et al. "3D-VLA: A 3D Vision-Language-Action Generative World Model." *ICML*, 2024.
- Hafner, D., et al. "DayDreamer: World Models for Physical Robot Learning." *CoRL*, 2022.
- Tobin, J., et al. "Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World." *IROS*, 2017.

提高作业提交要求

请将提高作业整理为 一份 PDF 提交。